Отчет.

В ходе работы я провел эксперименты с feature importance и добавил все в библиотеку на python. Сравнил feature importance в реализации sklearn и R, сравнил sklearn с R-ranger, а в конце произвел сравнение между реализациями: Sklearn, rfpimp, R RandomForest, R-ranger, RandomForestSRC, Party cforest, Partykit.

Эксперименты.

Использовал я датасет *rent.csv*, рассмотрел случаи, когда признаки: 1) разнородны, 2) присутствуют коррелированые признаки, 3) присутствуют нерелевантные признаки.

Sklearn vs R-randomforest

Подбор оптимальных гиперпараметров в реализации sklearn я осуществлял с помощью *Optuna*, и полученные параметры я использовал в реализации на R.

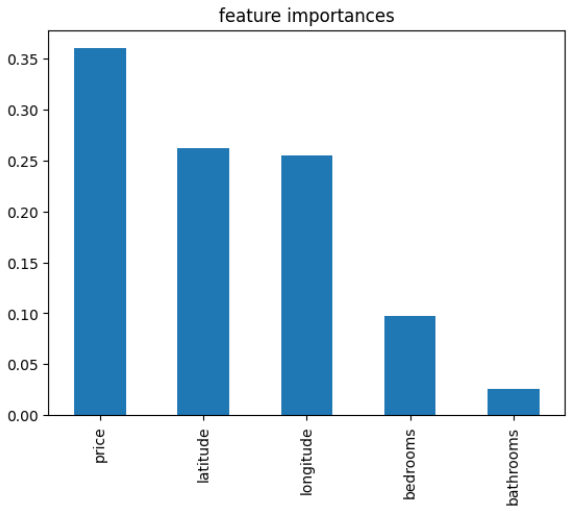

(a) Python: Исходный датасет

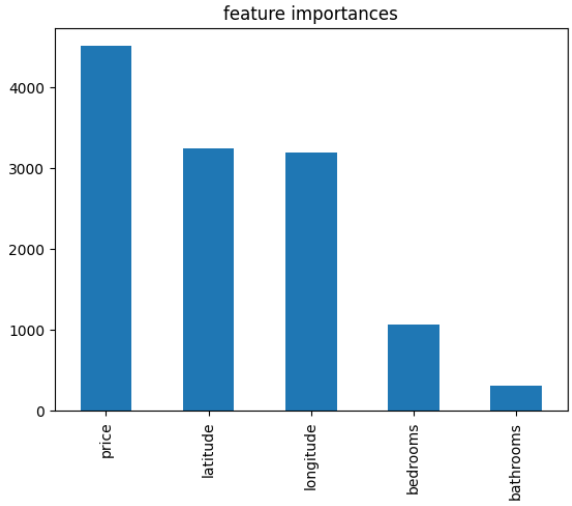

(a) R: Исходный датасет

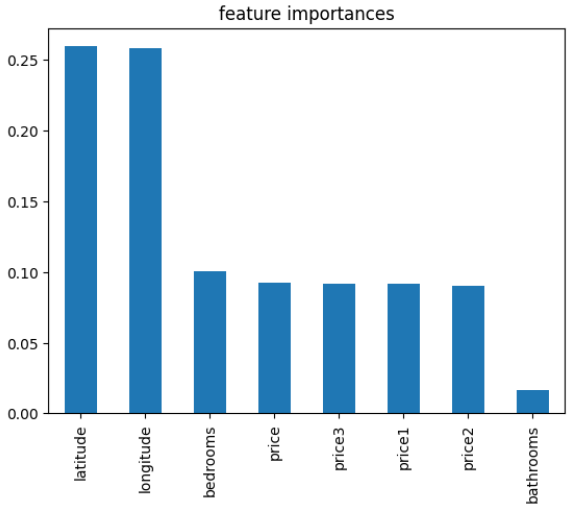

(b) Python: добавлены коррелированные признаки

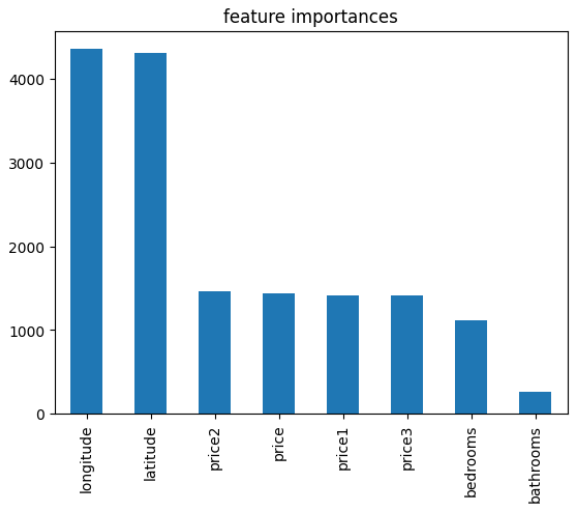

(b) R: добавлены коррелированные признаки

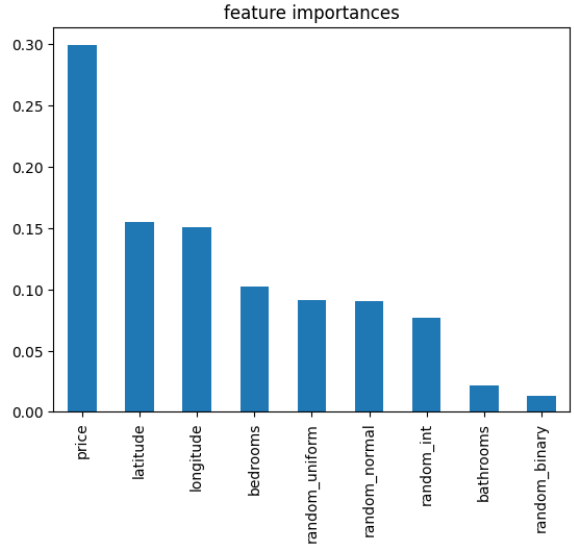

(c) Python: много нерелевантных признаков

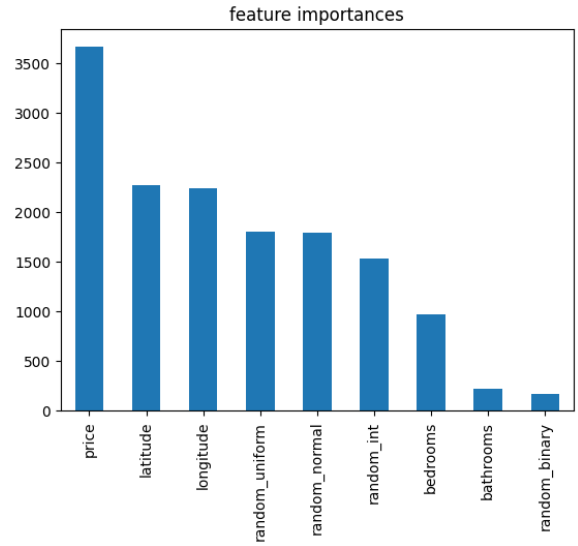

(c) R: много нерелевантных признаков

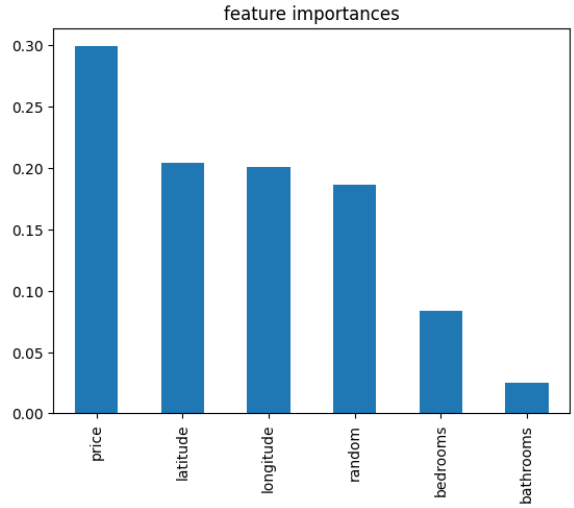

(d) Python: 1 нерелевантный признак

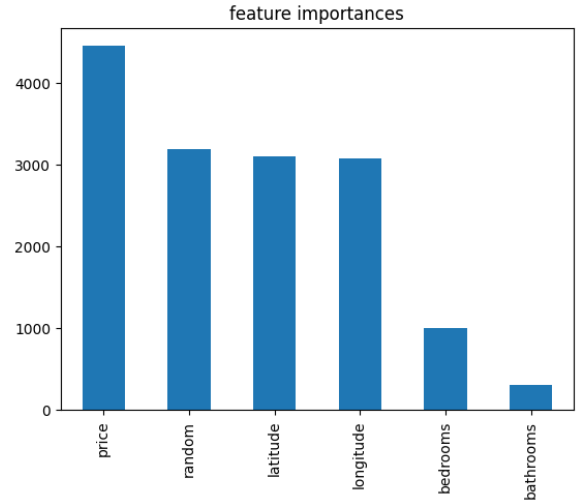

(d) R: 1 нерелевантный признак

Как можно заметить, результаты в некоторых экспериментах неожиданные.

В примере (b) я скопировал признак *price* 3 раза, и получилось, что важность этого признака уменьшилась. Вообще, при добавлении коррелированных признаков, важности этих признаков будут уменьшаться.

В примерах (c) и (d) я создал несколько признаков, которые никак не связаны с target.

Возникают вопросы, глядя на рисунки с нерелевантными признаками разного типа: 1) Почему эти признаки имеют важность? 2) Почему признаки $random\_uniform$, $random\_normal$, $random\_int$ имеют важность больше, чем признак $random\_binary$?

Ниже приведена таблица с оптимальными параметрами для каждого из примеров (a)-(d):

Пример	$n\_estimators$	max_depth	$min\_samples\_leaf$	$max\_features$
(a)	1760	26	5	sqrt
(b)	1289	14	3	1.0
(c)	1064	24	13	0.5
(d)	1096	19	3	0.3333333333333333

Sklearn vs R-ranger

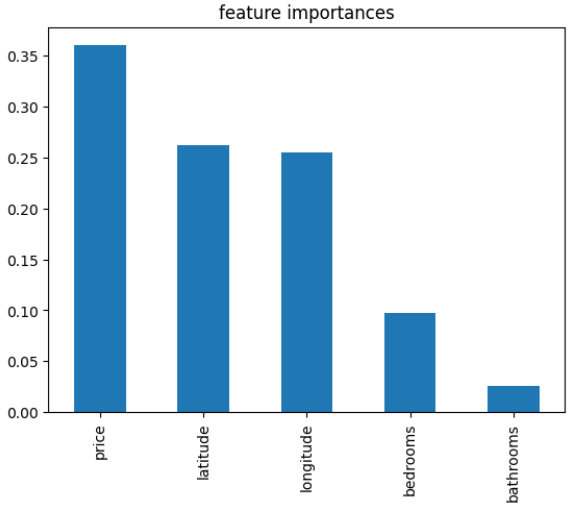

(a) Sklearn: Исходный датасет

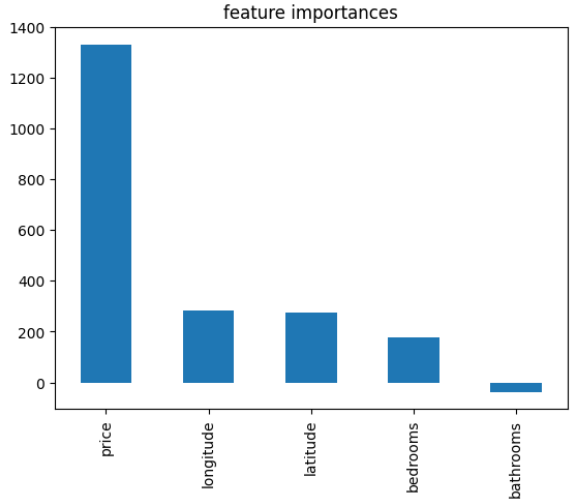

(a) R-ranger: Исходный датасет

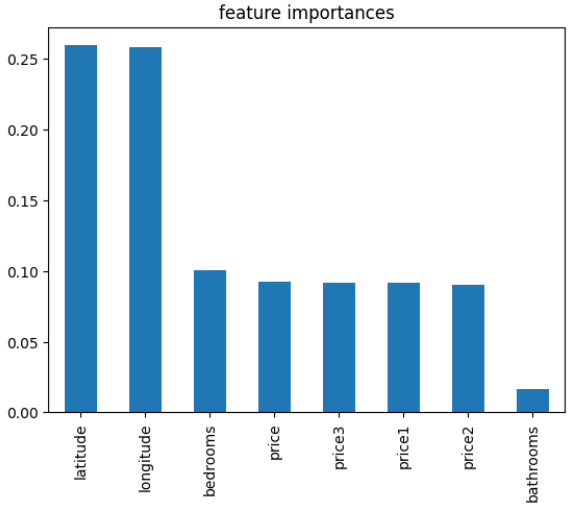

(b) Sklearn: добавлены коррелированные признаки

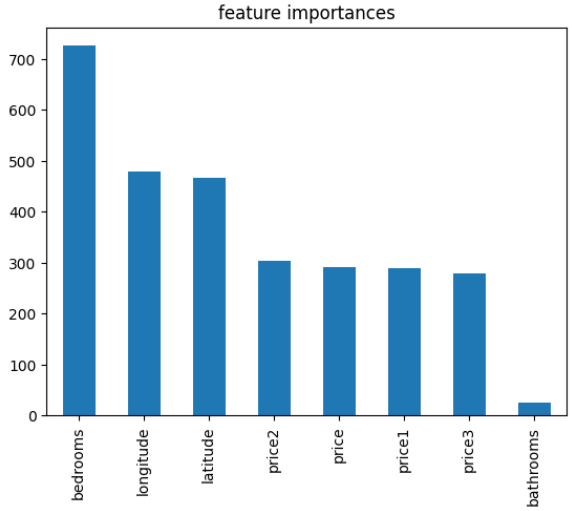

(b) R-ranger: добавлены коррелированные признаки

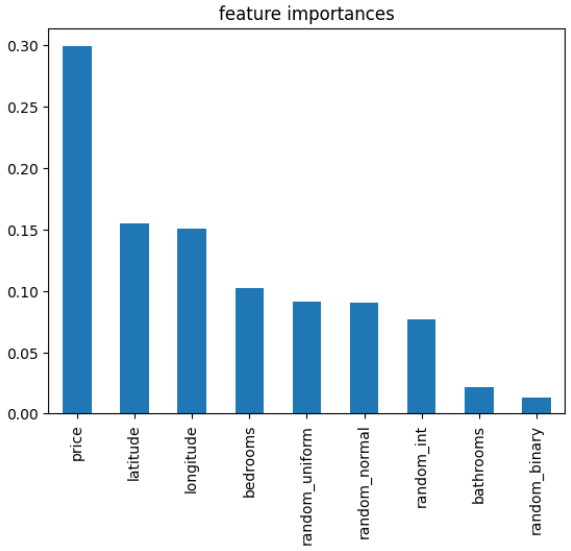

(c) Sklearn: много нерелевантных признаков

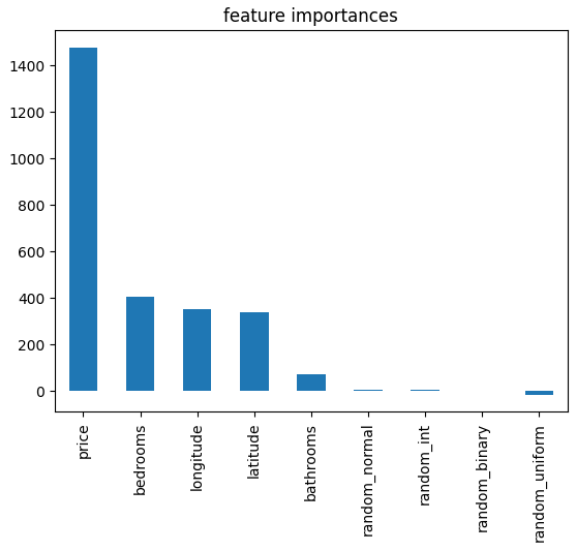

(c) R-ranger: много нерелевантных признаков

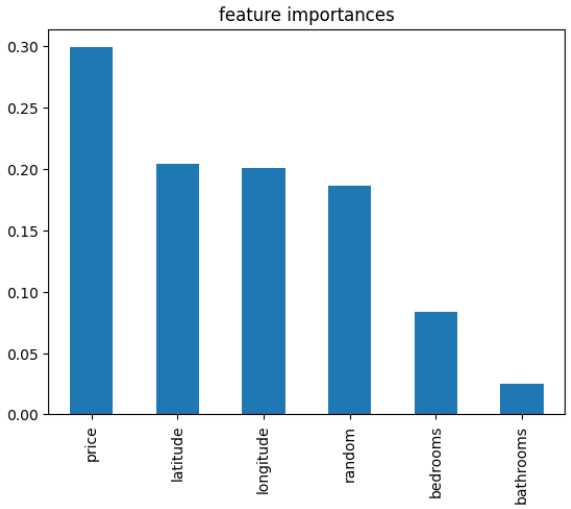

(d) Sklearn: 1 нерелевантный признак

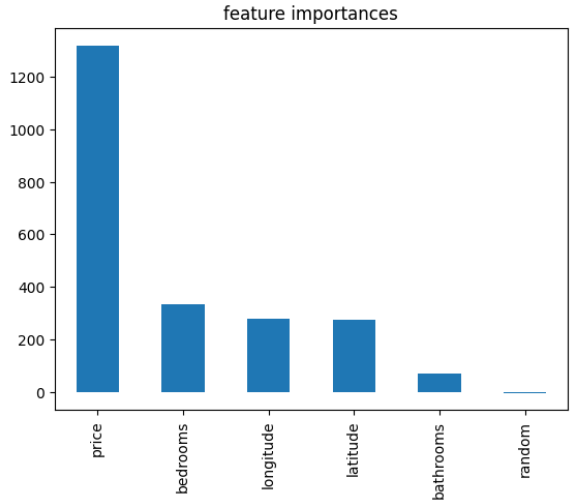

(d) R-ranger: 1 нерелевантный признак

Сравнение библиотек: Sklearn, rfpimp, R RandomForest, R-ranger, RandomForestSRC, Party cforest, Partykit

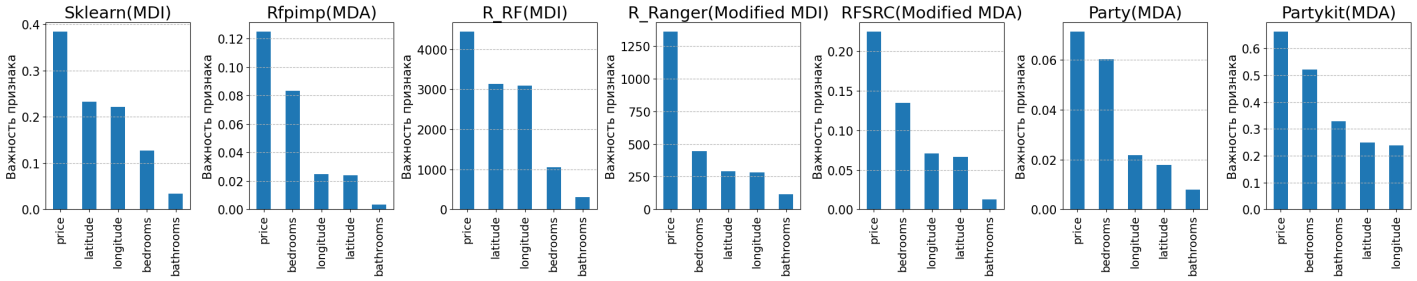

(a) Исходный датасет

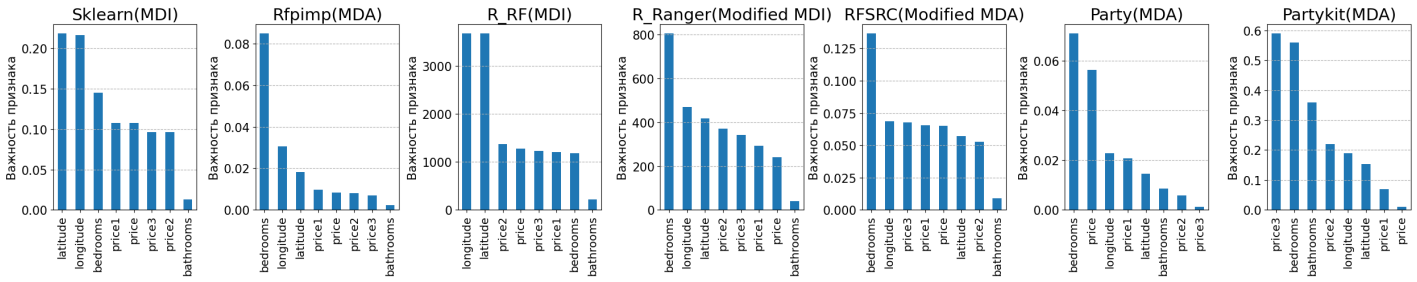

(b) Добавлены коррелированные признаки

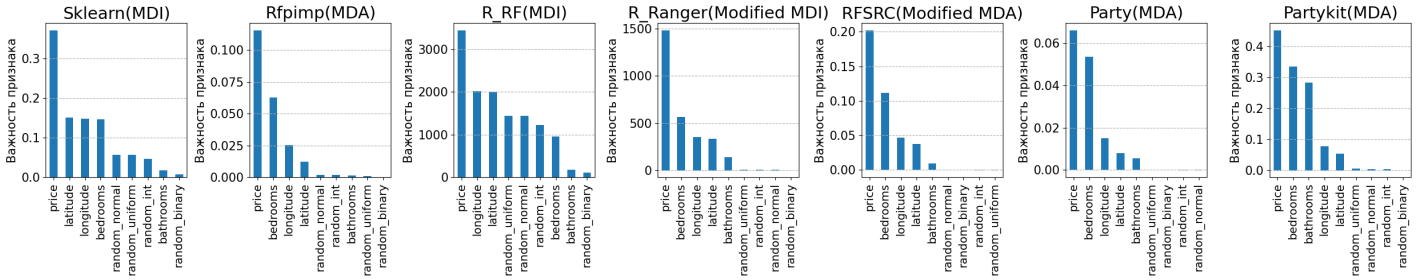

(c) Много нерелевантных признаков

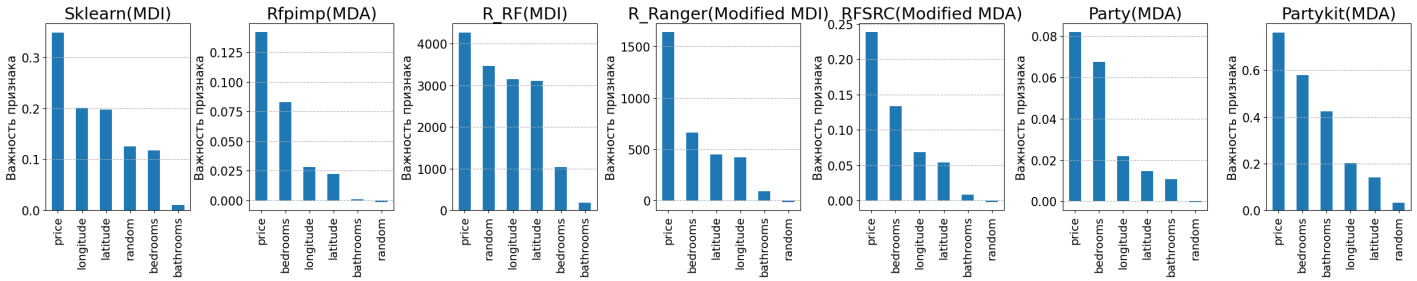

(d) 1 нерелевантный признак

Из эксперимента (*b*) видно, что важность одного из 4 продублированных признаков в пакетах party и partykit осталась примерно такой же, как в первом эксперименте, а у оставшихся 3 важность заметно ниже, в остальных реализациях важности этих признаков примерно одинаковая и примерно в 4 раза меньше важности признака price в 1 эксперименте.

Из эксперимента (c) видно, что важность нерелевантных признаков в пакетах rfpimp, ranger, randomforestsrc, party и partykit практически нулевая, в остальных реализациях эти признаки имеют ненулевую важность, причем у признака random_binary важность заметно ниже.

в эксперименте (d) тоже самое, важность признака random имеет большую важность в пакетах sklearn, r randomforest.